Twitter sentiment analysis using R with Sentiment 140 dataset

姓名: 顏懷瑾

學號:A4211050

學校:中國文化大學

學系:森保系五年級

研究主題

使用R語言以及其包含的機器學習工具包來進行機器學習中領域 内自然語言處理的情緒分析。

透過這次的主題,可以學習到 R 語言的語法、機器學習庫的應用、自然語言處理的流程、情緒分析上的難題。

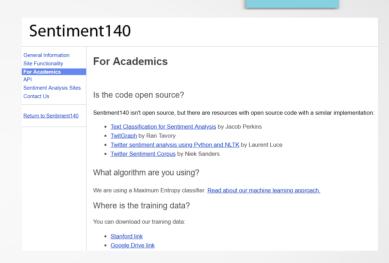
Machine Learning Using R

什麼是情緒分析?

- 情緒分析在現在的應用上有很多種,文字的、聲音的、影像的。
- 我們使用的資料集是屬於文字的資料集,故本次的專題是以文字 上的情緒分析為主。
- 以文字為主的情緒分析在目前又分為四個層次:
 - 1. 基於文件 (Documents-based) 的 ← 這次分析的層次
 - 2. 基於語句 (Sentences-based) 的
 - 3. 基於文字 (Words-based) 的
 - 4. 基於面向 (Aspect-based) 的

什麼是 Sentiment140?

- 該資料集的來源是 Stanford University 的 三位學生為了發表論文而使用 Twitter API 收集整理得到的英文資料,爾後便命名該資 料集為 Sentiment140。
- 該資料集也曾被用於 Kaggle 競賽中,許多專注於情緒分析的學生也會使用該資料集來做練習。
- Sentiment140 資料集的内容相當雜亂,因此用該資料及來做練習可以說相當的有挑戰性。



Twitter Sentiment Classification using Distant Supervision

Alec Go Stanford University Stanford, CA 94305 alecmgo@stanford.edu Richa Bhayani Stanford University Stanford, CA 94305 phayani@stanford edi Lei Huang Stanford University Stanford, CA 94305 leirocky@stanford.edu

開始分析:步驟 1 理解資料

- Sentiment140資料集等 共有元個欄位CoachChic","@yrclndstnlvr ahaha nooo you were just away from every sentiment140資料集等 共有元個欄位CoachChic","@BizCoachDeb Hey, I'm baack! And, thanks so much for a
 - "4" 21 17 sentiment: 情緒的正負向 (0代表負向情緒、1代表正向情緒)

1600000 "4", "2193602129", "Tue Jun 16 08:40:50 PDT 2009", "NO OUERY", "RyanTrevMorris", "happy #charitytuesday @theNSPCC @SparksCharity @Sp

- "219<mark>378date e 愛文的</mark>即形2009","NO_QUERY","xoAurixo","@oxhot theri tomorrow, drinking coffee, talking about ou "219<mark>378date de 爱文的</mark>即加入2009","NO_QUERY","RobFoxKerr","You heard it here first --- We're having a girl. Hope i

- 資料筆數9"160"萬筆8:39:00 PDT 2009", "NO_QUERY", "EvolveTom", "@Cliff_Forster Yeah, that does work better than just was 5

開始分析:步驟 2 使用 R 語言進行資料前處理

- 機器學習類別:監督式分類學習
- 使用的資料欄位:
 - 1. sentiment: 情緒的正負向
 - 2. text: 發文者的所撰寫的內容

- 1. 移除表情字符 (emoji)
- 2. 移除網址 (URL)
- 3. 移除錢號 (\$)
- 4. 移除換行符號 (\n)
- 5. 移除英文停用詞 (stop words)
- 6. 移除標點符號 (punctuation)
- 7. 移除多餘的空格 (Extra space)
- 8. 移除數字 (digit)

因為該資料集的特性,處理順序必須按照步驟

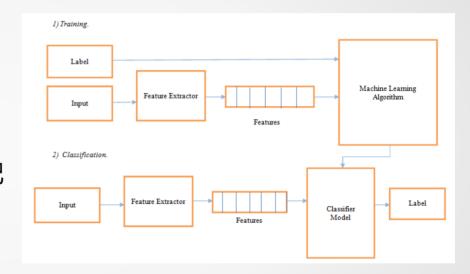
開始分析:步驟 3 檢查資料集完整性

- · 文字前處理後檢視資料發現有一些 NA 值在裡面,這種帶有標籤 (label) 卻沒有 tweet 的必須要去除
- 使用 stats 函式庫的 complete.cases() 來作清除

736553	0	2301859136	Tue Jun 23 16:00:32 PDT 2009	NO_QUERY	Rimfyre	NA
736554	0	2301859337	Tue Jun 23 16:00:33 PDT 2009	NO_QUERY	Ryanjhughes	buckingham palace wi fi
736555	0	2301859717	Tue Jun 23 16:00:35 PDT 2009	NO_QUERY	favadi	NA
736556	0	2301860269	Tue Jun 23 16:00:38 PDT 2009	NO_QUERY	fairy_windy	NA
736557	0	2301860738	Tue Jun 23 16:00:39 PDT 2009	NO QUERY	funmsdrebirth	verastic one hour late gosh cant believe

開始分析:步驟 4 機器學習中文字分析的典型流程(一)

- 分割訓練用資料集與測試用資料 集,80%用於訓練,20%用於測 試。
- 定義文檔術語矩陣 (document-term matrix) 與分詞 (tokenization) 用的配置。
- 建立詞彙表與文檔術語矩陣 (document-term matrix)



開始分析:步驟 5 機器學習中文字分析的典型流程 (二)

- 利用 TF-IDF 抽取真正有意義的詞
- 明明已經做過了停用詞 (stop words) 去除
- 為何還要用 TF-IDF 再篩選一次?
- 舉例:如果今天一位正常的人爆粗口,那麼他說的這個 詞彙就有很高的 TF-IDF 權重;相反的如果是館長的 發言,那麼同樣的詞彙的 TF-IDF 權重就會很低。

開始分析:步驟 6 訓練機器學習模型

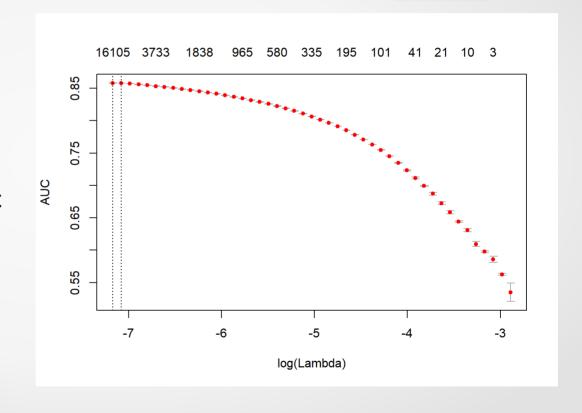
- 使用的模型:對數機率回歸 (Logistic Regression)
- 交叉驗證分割數:5折
- 模型訓練時間:46分鐘

```
print(difftime(Sys.time(), t1, units = 'mins'))
## Time difference of 46.64771 mins
```

```
# train the model
t1 <- Sys.time()
glmnet_classifier <- cv.glmnet(x = dtm_train_tfidf, y = t
family = 'binomial',
# L1 penalty
alpha = 1,
# interested in the area under ROC curve
type.measure = "auc",
# 5-fold cross-validation
nfolds = 5,
# high value is less accurate, but has faster training
thresh = 1e-3,
# again lower number of iterations for faster training
maxit = 1e3)</pre>
```

開始分析:步驟 7 使用曲線下面積 (AUC) 評估模型

- 何為 AUC?
- AUC的值必在 0~1之間
- AUC 值越高代表模型預 測率越準確
- 模型内的評估: max AUC= 0.8579
- 20% 測試資料集的 AUC = 0.8566717



心得

快樂的時間總是過得特別快,課堂上非常感激蔡老師的指導,課後也很感謝助教們細心的評閱我的作業,也替我解惑。就這樣在一次次的課程中慢慢進步,因為我非本科系的學生,在學習 R語言程式設計上顯得特別吃力,下課後幾乎用了所有的時間在碰撞中學習,卻從中漸漸的感覺到有趣,越練越開心,今天熬到了最後的專題報告,累積起來的知識可以說是收穫豐富,但學海無涯,還是要再次感謝蔡老師與助教們替我打開這道資料分析的大門。

